

UNIVERSITÉ DE LILLE
UFR3S – FACULTÉ DES SCIENCES DE LA SANTÉ ET DU SPORT
CENTRALE LILLE

MASTER 1 MANAGEMENT DE L'INTELLIGENCE ARTIFICIELLE EN SANTÉ (MIAS)

Unité d'Enseignement : Intelligence Artificielle & Santé

Année universitaire 2026–2027

RAPPORT DE PROJET

Système d'Aide à la Décision Médicale pour les Lésions Kystiques du Pancréas

*De la modélisation ontologique symbolique sous Protégé (OWL, SPARQL, SWRL)
à la fouille de données sous-symbolique sous Weka*

Auteurs :

PHAN Naëlle

ROBIN Alexis

Étudiants en Master 1 MIAS

Enseignant responsable :

Pr. Slim HAMMADI

Centrale Lille

Table des matières

1	Introduction	3
1.1	Contexte général	3
1.2	Problématique	3
1.3	La maladie : Les lésions kystiques du pancréas (LKP)	4
1.3.1	Rappels anatomiques et physiologiques	4
1.3.2	Nature et découverte des kystes	6
1.3.3	Classification et potentiel de dégénérescence	6
1.3.4	Critères sémiologiques et orientation thérapeutique	7
1.4	Organisation du document	7
2	Intelligence Artificielle Symbolique : Modélisation et Raisonnement sous Protégé	8
2.1	Objectifs et démarche de modélisation	8
2.2	Conception et structuration de l'ontologie OntoPLC	8
2.2.1	Création et architecture générale des classes	8
2.2.2	Hierarchisation des sous-classes et instanciation	9
2.3	Définition des propriétés sémantiques	10
2.3.1	Propriétés de données (Data Properties)	10
2.3.2	Propriétés d'objets (Object Properties)	10
2.4	Constitution de la base de cas cliniques	10
2.5	Sérialisation et formalisation en langage OWL	11
2.6	Interrogation sémantique de la base de connaissances via SPARQL	12
2.7	Raisonnement clinique et déduction de règles thérapeutiques en SWRL	14
2.8	Bilan méthodologique et limites de l'approche symbolique	16
3	Intelligence Artificielle Sous-symbolique : Fouille de Données avec Weka	17
3.1	Contexte méthodologique et protocole d'évaluation	17
3.1.1	Description du jeu de données	17
3.1.2	Justification du protocole de validation croisée	17
3.1.3	Critères et métriques d'évaluation de la performance	18
3.2	Expérimentation et comparaison des arbres de décision sous Weka Explorer	19
3.3	Analyse statistique sous Weka Experimenter : J48 versus Naive Bayes	20
3.4	Conception de flux et étude des courbes ROC sous Weka KnowledgeFlow	21
3.4.1	Visualisation du flux LMT et mise en évidence du surapprentissage	21
3.4.2	Comparaison par courbes ROC et analyse de l'AUC : Naive Bayes versus Random Forest	22
4	Discussion et Synergie des Deux Approches	25
4.1	Comparaison entre approche symbolique et sous-symbolique	25
4.2	Vers une architecture hybride d'aide à la décision (SADM)	25

5	Conclusion et Perspectives	27
5.1	Bilan du travail réalisé	27
5.2	Limites et perspectives d'évolution	27

1 Introduction

1.1 Contexte général

Le secteur de la santé fait face à une augmentation exponentielle du volume et de la complexité des données médicales. Qu'il s'agisse d'imagerie en coupe à haute résolution (scanner tomodensitométrique, imagerie par résonance magnétique), de bilans biologiques ou de comptes rendus anatomopathologiques, cette profusion d'informations rend l'intégration de l'informatique médicale et de l'intelligence artificielle indispensable à la conception de systèmes d'aide à la décision médicale (SADM).

Dans ce cadre, deux grands paradigmes de l'intelligence artificielle coexistent et se complètent :

- *L'intelligence artificielle symbolique* : fondée sur la modélisation explicite des connaissances d'un domaine métier à l'aide d'ontologies (formalisation en langage OWL sous l'environnement Protégé). Elle permet l'interrogation sémantique de la base de connaissances via le langage SPARQL et l'automatisation de déductions cliniques et thérapeutiques grâce à des règles logiques formalisées en SWRL (*Semantic Web Rule Language*). Sa valeur ajoutée réside dans sa traçabilité, son explicabilité et sa stricte cohérence avec les consensus médicaux.
- *L'intelligence artificielle sous-symbolique* : reposant sur la fouille de données (*data mining*) et l'apprentissage automatique (avec la suite logicielle Weka). À partir de données réelles de cohortes de patients, elle entraîne des modèles prédictifs (arbres de décision J48, LMT, Random Forest, classifieurs bayésiens) capables d'extraire des régularités statistiques, de gérer des données incomplètes ou bruitées et d'évaluer les performances diagnostiques au moyen de métriques quantitatives (matrices de confusion, sensibilité, spécificité, courbes ROC).

Ce travail vise à mobiliser conjointement ces deux approches pour répondre à une problématique diagnostique critique en gastroentérologie et oncologie digestive.

1.2 Problématique

Le diagnostic différentiel des affections pancréatiques constitue l'un des défis les plus ardues de la médecine actuelle. Bien que les techniques d'imagerie médicale modernes détectent des anomalies de façon très précoce, la décision clinique reste confrontée à plusieurs obstacles :

- *La complexité sémiologique et la variabilité inter-examens* : les paramètres radiologiques (taille, épaisseur des parois, cloisons internes, rehaussement vasculaire, bourgeons tissulaires, communications canalaire) sont nombreux, intriqués et parfois contradictoires d'un examen à l'autre (par exemple, un scanner concluant à une lésion séreuse bénigne alors que l'IRM suspecte une lésion mucineuse).

- *Le dilemme pronostique entre résection chirurgicale et surveillance* : d’une part, le cancer du pancréas présente une agressivité redoutable et un pronostic très sombre à cinq ans, ce qui impose une ablation chirurgicale rapide en présence de malignité avérée ou de haut grade de dysplasie. D’autre part, la chirurgie d’exérèse pancréatique (telle que la duodénopancréatectomie céphalique ou la spléno-pancréatectomie gauche) représente une intervention lourde, associée à une morbidité postopératoire notable (20 % à 40 % de complications majeures) et à un risque non négligeable de mortalité. Il est donc fondamental d’éviter toute chirurgie inutile chez des patients porteurs de kystes strictement bénins.
- *La nécessité d’un système unifié* : les modèles statistiques purs souffrent souvent d’un effet « boîte noire » difficilement acceptable pour le praticien, tandis que la démarche déductive manuelle peine à appréhender l’ensemble des interactions statistiques au sein de cohortes hétérogènes.

Dès lors, la question centrale de cette étude se formule ainsi : comment combiner une ontologie formelle du domaine (dédiée à la représentation explicite des connaissances, aux requêtes sémantiques et aux règles de prise en charge) et des modèles de fouille de données sous-symboliques pour guider avec précision la classification nosologique et la décision thérapeutique face à des lésions pancréatiques ?

1.3 La maladie : Les lésions kystiques du pancréas (LKP)

1.3.1 Rappels anatomiques et physiologiques

Le pancréas est un organe rétro-péritonéal vital, situé transversalement en arrière de l’estomac, entre le cadre duodénal à droite et la rate à gauche. Sur le plan morphologique, il se divise en plusieurs segments anatomiques distincts, illustrés sur la figure 1 :

- *La tête* : segment le plus large et volumineux, étroitement moulé dans la concavité duodénale ;
- *L’uncus (processus unciné)* : prolongement inférieur en forme de crochet prolongeant la tête et passant en arrière des vaisseaux mésentériques supérieurs ;
- *L’isthme (ou col)* : segment rétréci reliant la tête au corps de l’organe ;
- *Le corps* : portion principale allongée s’étendant horizontalement vers la gauche ;
- *La queue* : extrémité distale effilée dirigée vers le hile splénique.

Cette segmentation topographique est fondamentale en pratique clinique, car la bénignité ou la malignité d’une lésion kystique est fréquemment corrélée à son siège anatomique (par exemple, les cystadénomes mucineux prédominent au niveau du corps et de la queue, tandis que les cystadénomes séreux ou les TIPMP peuvent concerner la tête). Dans ce projet, ces cinq régions constituent précisément les attributs d’entrée de localisation encodés dans l’ontologie OntoPLC et dans la base de données de classification.




FIGURE 1 – Organisation anatomique du pancréas : segmentation morphologique (tête, uncus, isthme, corps, queue) et réseau canalaire (canaux de Wirsung et de Santorini).

Le schéma met également en évidence le réseau canalaire qui draine les sécrétions pancréatiques :

- *Le canal de Wirsung (canal pancréatique principal)* : traverse l'organe sur toute sa longueur, de la queue à la tête, pour s'aboucher dans le duodénum au niveau de l'ampoule hépato-pancréatique (ampoule de Vater). L'analyse de son diamètre (recherche d'une dilatation anormale) et de sa communication avec un kyste constitue le critère sémiologique clé pour identifier les TIPMP.
- *Le canal de Santorini (canal pancréatique accessoire)* : draine préférentiellement la région antéro-supérieure de la tête du pancréas.

Sur le plan fonctionnel, le pancréas exerce une double fonction biologique essentielle à l'organisme :

1. *Une fonction exocrine* (représentant environ 90 % du parenchyme) : assurée par les acini glandulaires qui synthétisent le suc pancréatique riche en pro-enzymes digestives (lipase, amylase, trypsinogène) destinées à être déversées dans la lumière duodénale.
2. *Une fonction endocrine* (assurée par les îlots de Langerhans disséminés dans le tissu) : responsable de la production et de la libération directe dans la circulation sanguine d'hormones majeures de l'homéostasie métabolique, principalement l'insuline (cellules bêta) et le glucagon (cellules alpha).

1.3.2 Nature et découverte des kystes

Une lésion kystique pancréatique est une structure anormale contenant une phase liquidienne ou mixte (tissulaire et liquide), délimitée ou non par un épithélium. L'usage croissant de l'imagerie abdominale pour des motifs variés a conduit à une hausse spectaculaire de leur détection fortuite, qualifiée d'incidentalomes.

1.3.3 Classification et potentiel de dégénérescence

D'un point de vue médical et pronostique, les lésions kystiques se subdivisent en trois grandes catégories :

1. *Les lésions bénignes sans potentiel malin :*

- Le cystadénome séreux (CAS) : tumeur bénigne le plus souvent microkystique, avec un aspect typique en nid d'abeille et parfois une cicatrice centrale calcifiée. Présente surtout chez la femme après 60 ans, elle ne nécessite qu'une simple abstention thérapeutique en l'absence de compression d'organes voisins.
- Le pseudokyste (PC) : cavité liquidienne dépourvue de revêtement épithélial propre, faisant suite à un épisode de pancréatite aiguë ou survenant sur une pancréatite chronique.
- Le kyste hydatique (KH) : lésion infectieuse d'origine parasitaire (*Echinococcus granulosus*), plus rare mais envisageable dans le diagnostic différentiel.

2. *Les lésions prénéoplasiques à potentiel malin (borderline) :*

- Le cystadénome mucineux (CAM) : lésion macrokystique à paroi épaisse se développant quasi exclusivement chez la femme, localisée préférentiellement au niveau du corps ou de la queue du pancréas. Son risque prouvé de transformation en adénocarcinome justifie le plus souvent une exérèse chirurgicale préventive.
- La tumeur intracanalair papillaire et mucineuse du pancréas (TIPMP) : prolifération mucineuse prenant naissance dans le canal de Wirsung ou les canaux secondaires, dont le risque de dégénérescence dépend étroitement de la taille du kyste, du calibre canalaire et de la présence de nodules muraux.
- La tumeur pseudo-papillaire et solide (TPPS, ou tumeur de Frantz) : tumeur rare touchant préférentiellement la femme jeune, présentant un potentiel d'agressivité locale intermédiaire.

3. *Les lésions malignes confirmées :*

- Le cystadénocarcinome mucineux (CADKM) et l'adénocarcinome canalaire (ADK) à composante nécrotique ou kystique, caractérisés par une invasion tissulaire rapide, un risque métastatique élevé et une dégradation de l'état général du patient.
- Les tumeurs neuroendocrines kystiques (TNE), dont certaines formes peuvent s'intégrer dans des syndromes génétiques complexes tels que la néoplasie en-

docrinienne multiple de type 1 (NEM1) ou la maladie de Von Hippel-Lindau (VHL).

1.3.4 Critères sémiologiques et orientation thérapeutique

La démarche diagnostique repose sur le recueil et l'analyse minutieuse de paramètres discriminants :

- Des variables cliniques et anamnestiques : âge, sexe, antécédents personnels et familiaux de pancréatite ou d'interventions chirurgicales.
- Des marqueurs tumoraux sériques : notamment les taux de CA 19-9, d'ACE et de CA 125.
- Des critères morphologiques radiologiques (TDM et IRM) : topographie de la lésion (tête, isthme, corps, queue, uncus), volume, architecture uniloculaire ou multiloculaire, présence de septa fins ou épais, nodules muraux vascularisés, dilatation du canal de Wirsung et présence éventuelle d'anomalies extra-pancréatiques (métastases, adénomégalies).

La confrontation méthodique de ces données conditionne le choix de la prise en charge : abstention thérapeutique, surveillance radiologique rapprochée, ou résection chirurgicale programmée.

1.4 Organisation du document

Le présent rapport est structuré de la manière suivante :

- La section 2 présente l'approche par intelligence artificielle symbolique, en détaillant la construction de l'ontologie OntoPLC sous Protégé, l'exécution des requêtes SPARQL et l'application des règles d'inférence SWRL.
- La section 3 est consacrée à l'intelligence artificielle sous-symbolique, abordant la préparation des données sous Weka, la mise en œuvre de plusieurs modèles de classification supervisée et l'analyse de leurs performances respectives.
- La section 4 propose une conclusion générale et ouvre des perspectives pour l'intégration conjointe de ces deux technologies au sein d'un environnement clinique.

2 Intelligence Artificielle Symbolique : Modélisation et Raisonnement sous Protégé

2.1 Objectifs et démarche de modélisation

Le volet symbolique du projet a pour objectif de modéliser les connaissances relatives aux lésions kystiques du pancréas dans une ontologie intitulée *OntoPLC*. À partir des tableaux du cahier des charges médical, le travail consistait à organiser les classes et leurs instances, à définir les propriétés, puis à représenter des cas de patients. L'ontologie obtenue devait ensuite être visualisée en OWL, interrogée avec SPARQL et complétée par une règle SWRL de prise en charge thérapeutique.

Ce travail s'inscrit dans l'aide à la décision médicale présentée en cours : réunir les observations d'un patient et les connaissances du domaine pour éclairer le diagnostic et la prise en charge. L'ontologie fournit un vocabulaire explicite et partagé, plutôt qu'une simple juxtaposition de données.¹

Ce chapitre présente la conception de l'ontologie, sa formalisation et son exploitation clinique. Le modèle et les cas sont illustrés dans *Protégé*, et le fichier de travail est `OntoPLC_complete.owl`. La requête SPARQL est exécutée avec Python et RDFLib ; la démonstration d'inférence est réalisée dans Protégé avec l'extension SWRLTab et son moteur Drools. Les captures et les extraits suivants montrent le modèle obtenu et les résultats de son exploitation.

2.2 Conception et structuration de l'ontologie OntoPLC

2.2.1 Création et architecture générale des classes

L'ontologie de domaine est intitulée `OntoPLC`. Le fichier de travail `OntoPLC_complete.owl` rassemble sa structure, les cas et la règle. Ses entités utilisent l'espace de noms <http://www.semanticweb.org/ontologies/2026/8/OntoPLC>, repris dans les extraits OWL et SPARQL.

Le modèle reprend les huit classes principales du cahier des charges médical sous la racine `owl:Thing` (tableau 1). Dans l'onglet *Classes* de Protégé, cette organisation sépare le contexte du patient, la description des lésions, les éléments diagnostiques et les traitements. Ces grandes catégories constituent le *modèle générique* du cours. Leur spécialisation en sous-classes et en propriétés adaptées aux lésions pancréatiques forme le *modèle de domaine* (diapositives 82–84).

1. Support de cours, *Master M1 MIAS : IA & Santé – Enjeux, Technologies, méthodes et outils*, support de cours, diapositives 26–27 et 56–57.

TABLE 1 – Classes principales d’OntoPLC

Classe	Rôle
Antecedent	Antécédents et habitudes de vie.
Consequences	Évolutions et anomalies associées aux lésions.
Cystic_features	Caractéristiques observées des lésions kystiques.
Diagnostic	Examens, signes et résultats diagnostiques.
Diseases	Maladies et catégories de lésions.
Patient	Patients et catégories descriptives associées.
Symptoms	Symptômes observés ou rapportés.
Treatment	Modalités de traitement.

2.2.2 Hiérarchisation des sous-classes et instanciation

Ces classes sont organisées en sous-classes pour préciser le domaine. Par exemple, `patient_ID` est rattachée à `Patient`, tandis que `Medical_Treatment` est rattachée à `Treatment`. Les individus `patient01` à `patient76` appartiennent à `patient_ID`, et `Abstention` est un individu de `Medical_Treatment`. Ces exemples distinguent la hiérarchie des catégories de leurs instances : `Patient` est une classe, alors que `patient01` représente un cas particulier.




FIGURE 2 – Hiérarchie des classes d’OntoPLC dans Protégé.

2.3 Définition des propriétés sémantiques

La hiérarchie des classes est complétée par la définition de propriétés de données et de propriétés d’objets. Les premières associent une valeur littérale à un individu ; les secondes relient deux individus. Dans Protégé, leurs déclarations sont accessibles respectivement dans *Data Properties* et *Object Properties*, avec les champs *Domain* et *Range*.

2.3.1 Propriétés de données (Data Properties)

Pour les données numériques, **has_age** est déclarée avec le domaine **Age** et le type `xsd:nonNegativeInteger`, conformément au tableau du cahier des charges médical. La taille du kyste est représentée par **has_size**, de domaine **Size_Of_Cystic** et de type `xsd:decimal`. Ces déclarations distinguent notamment l’âge entier d’une mesure pouvant comporter des décimales.

2.3.2 Propriétés d’objets (Object Properties)

Les relations entre individus complètent les valeurs numériques. Leurs domaines et portées sont précisés dans le tableau 2.

TABLE 2 – Propriétés d’objet utilisées pour représenter et exploiter les cas

Propriété	Domaine	Portée
has_sex	Patient	Sexe
is_sick_by	Patient	Cystic_Pancreatic_Lesions
has_diagnosed	Cystic_Pancreatic_Lesions	Diagnostic
has_type_of_lesion	Diagnostic_Result	Type_of_Lesions_Pancreatic
has_treated_by	Cystic_Pancreatic_Lesions	Treatment

Le tableau 2 présente les relations mobilisées dans la suite du projet. Le sexe est ici un lien vers un individu, tel que **femme**, et non une chaîne de caractères. De même, le diagnostic et le traitement ne sont pas de simples attributs du patient : le premier est atteint à partir de la lésion, et le second est associé à celle-ci. Cette organisation détermine les chemins à utiliser dans la requête et dans la règle.

2.4 Constitution de la base de cas cliniques

La démarche passe ensuite du niveau conceptuel à une base de cas cliniques réels, en instanciant les patients et leurs assertions. Le fichier obtenu contient 76 patients de type **patient_ID**, avec des liens vers les lésions et les diagnostics. Les annotations de provenance font référence à **BDD_pancreas.xlsx**. Dans *Individuals by class*, la description d’un patient rassemble son type, ses *Object property assertions* et ses *Data property assertions*. Les assertions propres à chaque patient constituent le troisième niveau présenté en cours : le *modèle de cas* (diapositives 97–98). La structure du domaine est ainsi réutilisée pour décrire chaque scénario diagnostique.

Le cas `patient01` illustre l'organisation des assertions. Il décrit une femme de 22 ans, reliée à `lesion_patient01`, puis au diagnostic `diagnostic_patient01`. Le type de lésion associé est l'individu `Mucinous_Cystic_Neoplasm`. Le chemin se lit comme suit :

Listing 1 – Relations du cas `patient01` (noms locaux des IRI)

<code>patient01</code>	<code>--is_sick_by--></code>	<code>lesion_patient01</code>
<code>lesion_patient01</code>	<code>--has_diagnosed--></code>	<code>diagnostic_patient01</code>
<code>diagnostic_patient01</code>	<code>--has_type_of_lesion--></code>	<code>Mucinous_Cystic_Neoplasm</code>




FIGURE 3 – Assertions de `patient01` dans l'onglet `Individuals by class` : type, âge, sexe et lien vers la lésion.

La figure 3 montre la correspondance entre le cas et sa représentation dans Protégé : l'âge 22 est une assertion de données, tandis que le sexe et la lésion sont des assertions d'objet. En suivant `is_sick_by`, puis `has_diagnosed`, on retrouve le diagnostic associé. Ce parcours permet de lire un scénario complet sans confondre le patient, sa lésion et le résultat diagnostique.

2.5 Sérialisation et formalisation en langage OWL

Cette étape relie les vues de Protégé au langage OWL (*Web Ontology Language*) utilisé pour enregistrer l'ontologie. Le fichier `OntoPLC_complete.owl` utilise la syntaxe RDF/XML. L'extrait ci-dessous reprend la déclaration de la classe `patient_ID` et les principales assertions de `patient01`. Pour faciliter la lecture, les IRI des entités sont écrites sous forme relative à `xml:base` ; les autres assertions du patient sont omises.

Listing 2 – Extrait OWL du modèle et du cas patient01 en RDF/XML

```
<rdf:RDF
  xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
  xmlns:rdfs="http://www.w3.org/2000/01/rdf-schema#"
  xmlns:owl="http://www.w3.org/2002/07/owl#"
  xmlns="http://www.semanticweb.org/ontologies/2026/8/OntoPLC#"
  xml:base="http://www.semanticweb.org/ontologies/2026/8/OntoPLC">
  <owl:Class rdf:about="#patient_ID">
    <rdfs:subClassOf rdf:resource="#Patient"/>
  </owl:Class>
  <owl:NamedIndividual rdf:about="#patient01">
    <rdf:type rdf:resource="#patient_ID"/>
    <has_sex rdf:resource="#femme"/>
    <is_sick_by rdf:resource="#lesion_patient01"/>
    <has_age
      rdf:datatype="http://www.w3.org/2001/XMLSchema#nonNegativeInteger"
      >22</has_age>
  </owl:NamedIndividual>
</rdf:RDF>
```

La balise `owl:Class` déclare la classe, et `rdfs:subClassOf` exprime son rattachement à `Patient`. La balise `owl:NamedIndividual` décrit ensuite le patient : `rdf:type` indique sa classe, `rdf:resource` désigne les individus liés, et `rdf:datatype` précise le type de la valeur 22. On retrouve ainsi dans le fichier les mêmes informations que dans la vue de Protégé, sous une forme exploitable par la requête SPARQL.

2.6 Interrogation sémantique de la base de connaissances via SPARQL

Afin d'interroger sémantiquement la base de connaissances, la requête suivante extrait les identifiants des patients, leur sexe et les résultats diagnostiques. Elle est enregistrée dans `requetes/patients_diagnostics.rq`. Le préfixe `ontoplc` reprend l'espace de noms d'OntoPLC. Le chemin sémantique d'accès aux triplets a été configuré à la représentation des cas : le type de lésion est recherché sur le diagnostic, atteint en passant par la lésion.

Listing 3 – Requête d'extraction des patients et de leurs diagnostics

```
PREFIX ontoplc: <http://www.semanticweb.org/ontologies/2026/8/OntoPLC#>
SELECT DISTINCT ?Patient ?Sexe ?Type_of_Lesions_Pancreatic ?Malignant_Potential
WHERE {
  ?Patient a ontoplc:patient_ID .
  OPTIONAL { ?Patient ontoplc:has_sex ?Sexe . }
  OPTIONAL {
    ?Patient ontoplc:is_sick_by ?Lesion .
    OPTIONAL {
      ?Lesion ontoplc:has_diagnosed ?Diagnostic .
      ?Diagnostic ontoplc:has_type_of_lesion ?Type_of_Lesions_Pancreatic .
    }
  }
  OPTIONAL {
    ?Lesion ontoplc:has_malignant_potentiel ?Malignant_Potential .
  }
}
```

```

}
}
ORDER BY ?Patient

```

Le type explicite `patient_ID` permet de sélectionner les patients sans calcul préalable des types inférés. Les blocs `OPTIONAL` conservent un patient même si le sexe, la lésion ou une information diagnostique manque. La même variable `?Lesion` est utilisée pour rechercher le diagnostic et la malignité, afin de ne pas mélanger deux lésions. `DISTINCT` élimine les lignes identiques, mais plusieurs valeurs distinctes peuvent produire plusieurs lignes pour un même patient.

L'exécution de la requête avec `requetes/executer_sparql.py` et `RDFLib 7.6.0` a produit 76 lignes, exportées dans `patients_diagnostics.csv`. Pour ces données, chaque patient apparaît une fois. Le tableau 3 présente les premiers résultats, avec des noms locaux à la place des IRI complètes du CSV. On retrouve notamment le sexe et le type de lésion du cas `patient01` décrit dans Protégé.

TABLE 3 – Extrait des résultats SPARQL

Patient	Sexe	Type de lésion	Potentiel malin
patient01	femme	Mucinous_Cystic_Neoplasm	non renseigné
patient02	femme	Mucinous_Cystic_Neoplasm	non renseigné
patient03	femme	mucinous_cystadenoma	non renseigné
patient04	femme	mucinous_cystadenoma	non renseigné

```

$ Ontologie/.venv/bin/python Ontologie/requetes/executer_sparql.py

Ontologie : /home/arobin/Documents/Cours/IA/Ontologie/OntoPLC_complete.owl
Requête : /home/arobin/Documents/Cours/IA/Ontologie/requetes/patients_diagnostics.rq
Sortie CSV : /home/arobin/Documents/Cours/IA/Ontologie/requetes/patients_diagnostics.csv
RDFLib : 7.6.0
Nombre de lignes : 76
Patient | Sexe | Type_of_Lesions_Pancreatic | Malignant_Potential
patient01 | femme | Mucinous_Cystic_Neoplasm | non renseigné
patient02 | femme | Mucinous_Cystic_Neoplasm | non renseigné
patient03 | femme | mucinous_cystadenoma | non renseigné
patient04 | femme | mucinous_cystadenoma | non renseigné
patient05 | femme | mucinous_cystadenoma | non renseigné
patient06 | femme | Pancreatic_Adenocarcinoma | non renseigné
patient07 | femme | mucinous_cystadenoma | non renseigné
patient08 | femme | mucinous_cystadenoma | non renseigné
patient09 | femme | Serous_cystadenoma | non renseigné
patient10 | femme | Serous_cystadenoma | non renseigné
$ |

```

FIGURE 4 – Exécution et affichage des résultats de la requête dans l'onglet SPARQL de Protégé.

Aucune assertion `has_malignant_potentiel` n'est enregistrée pour les lésions importées. La colonne correspondante est donc vide dans le CSV et affichée « non renseigné » dans l'aperçu. L'existence des individus `Malignant`, `Benign` et `Borderline` dans le vocabulaire ne suffit pas à attribuer une valeur à une lésion. Une absence d'information ne signifie pas que la lésion est bénigne.

2.7 Raisonnement clinique et déduction de règles thérapeutiques en SWRL

Au-delà de l'interrogation de faits connus, le système formalise des règles logiques pour déduire des recommandations de prise en charge. La règle retenue associe `Abstention` à une lésion lorsque le patient a strictement plus de 80 ans et que cette même lésion est déclarée maligne et métastatique. SWRL permet ici d'exprimer une implication : lorsque toutes les conditions du corps sont satisfaites, la relation indiquée dans la tête est déduite.

Il s'agit d'un *raisonnement déductif* : une règle explicite est appliquée à des faits connus, sans apprentissage à partir d'exemples (cours, diapositives 19 et 103–104). Dans cette réalisation, SPARQL restitue les faits enregistrés, alors que SWRL ajoute une assertion entre des individus existants, matérialisant une déduction clinique sans créer de nouveaux individus.

Listing 4 – Règle SWRL enregistrée dans OntoPLC

```

ontoplc:Patient(?p) ^
ontoplc:is_sick_by(?p, ?l) ^
ontoplc:has_age(?p, ?age) ^
swrlb:greaterThan(?age, 80) ^
ontoplc:has_malignant_potentiel(?l, ontoplc:Malignant) ^
ontoplc:has_resulted_extra_anomaly(?l, ontoplc:Metastatic)
-> ontoplc:has_treated_by(?l, ontoplc:Abstention)

```

Deux adaptations assurent la correspondance avec le modèle réalisé. D'une part, la variable `?l` désigne la lésion du patient et porte les observations ainsi que le traitement déduit. D'autre part, la constante `Malignant` remplace la variable `?malign` initiale afin d'exiger effectivement une lésion maligne. Le corps comporte six conditions ; `greaterThan(?age, 80)` impose un seuil strict et exclut donc l'âge de 80 ans.

La règle est conservée dans `regles/abstention.swrl` et enregistrée comme axiome `swrl:Imp` dans `OntoPLC_complete.owl`. Pour vérifier son déclenchement malgré l'absence de malignité dans les cas importés, une copie distincte, `OntoPLC_demo_swrl.owl`, contient six patients fictifs et sept lésions. Aucun traitement n'est initialement associé à ces lésions.

L'exécution dans SWRLTab s'est déroulée en trois étapes : transfert des axiomes avec *OWL+SWRL*, lancement du moteur avec *Run Drools*, puis réintégration des inférences avec *Drools->OWL*. La figure 5 présente la règle et le journal d'exécution. Le résultat sauvegardé est conservé dans `OntoPLC_demo_swrl.owx` et dans sa version RDF/XML `OntoPLC_demo_swrl_infere.owl`.




FIGURE 5 – Règle dans SWRLTab et journal d’exécution du moteur Drools.

TABLE 4 – Vérification sur les cas fictifs : résultats attendus et retrouvés dans la sortie sauvegardée

Cas	Conditions	Relation ajoutée
Positif	81 ans, malignité et métastase sur la même lésion.	Abstention sur la lésion positive.
Seuil d’âge	80 ans, autres conditions satisfaites.	Aucune.
Lésion bénigne	Benign au lieu de Malignant .	Aucune.
Métastase absente	Malignité renseignée, sans Metastatic .	Aucune.
Malignité absente	Métastase renseignée, sans potentiel malin.	Aucune.
Deux lésions	Une lésion maligne et une autre métastatique.	Aucune sur les deux.

La comparaison des fichiers avant et après exécution retrouve exactement une nouvelle relation thérapeutique parmi les lésions fictives : `lesion_positif has_treated_by Abstention`. Les six autres lésions ne reçoivent pas cette relation. Le cas à deux lésions vérifie en particulier que la règle ne combine pas abusivement des observations issues de lésions différentes.




FIGURE 6 – Détail des assertions de `lesion_positif` : la relation `has_treated_by Abstention` apparaît après l'inférence. Les captures sont recadrées sur le panneau des propriétés.

2.8 Bilan méthodologique et limites de l'approche symbolique

La principale difficulté a été d'adapter le corrigé à la structure des cas. Les variables distinctes pour le patient, la lésion et le diagnostic permettent de respecter les relations du modèle, sans attribuer toutes les informations directement au patient.

Le potentiel de malignité absent limite l'exploitation des cas importés. Les blocs `OPTIONAL` conservent les patients dans les résultats, et les cas fictifs permettent de vérifier la règle sans inventer de données médicales. Le classeur cité dans les annotations n'étant pas disponible, la conformité de l'import aux données d'origine reste non vérifiée.

Enfin, un domaine OWL infère un type sans contrôler la saisie : le domaine `Age` de `has_age`, repris du cahier des charges médical, classe aussi les patients concernés dans `Age`. Un fait absent n'est pas nécessairement faux. Les résultats SWRL démontrent donc l'application d'une règle pédagogique, et non la pertinence clinique d'un traitement.

Ces opérations s'intègrent dans l'architecture globale d'aide au diagnostic DIAT-PLC, qui associe extraction SPARQL, classification avec Weka et raisonnement SWRL (diapositives 108–110). Ce travail illustre la rigueur de la représentation des connaissances et du raisonnement déductif ; il s'articule naturellement avec l'apprentissage sous-symbolique. Les outils effectivement employés sont RDFLib et Drools, et non Jena et Jess comme dans l'architecture du cours. Ce lien éclaire la complémentarité avec la partie Weka du rapport, sans supposer que le CSV produit a alimenté les expériences d'apprentissage.

3 Intelligence Artificielle Sous-symbolique : Fouille de Données avec Weka

3.1 Contexte méthodologique et protocole d'évaluation

Le volet sous-symbolique (également désigné sous les termes d'intelligence artificielle sub-symbolique, statistique ou connexionniste) vise à extraire des connaissances et des motifs prédictifs directement à partir de données cliniques empiriques, sans modélisation formelle a priori des règles médicales. Ce chapitre s'appuie sur la suite logicielle Weka (*Waikato Environment for Knowledge Analysis*) pour analyser le jeu de données des lésions kystiques du pancréas et construire des modèles de classification supervisée.

3.1.1 Description du jeu de données

Le jeu de données étudié (fichier `plc.arff` ou `versionameliotyp112.arff`) regroupe 73 cas de patients documentés selon 52 variables hétérogènes :

- Données cliniques et anamnestiques : âge, sexe, antécédents d'hypertension artérielle, de diabète, de pancréatite aiguë ou chronique, antécédents néoplasiques ou chirurgicaux.
- Marqueurs biologiques : dosages sériques du CA 19-9, du CA 125 et de l'ACE.
- Caractéristiques morphologiques et sémiologiques : taille, forme, topographie lésionnelle (tête, isthme, corps, queue, uncus), épaisseur de paroi, présence de nodules muraux, calcifications, cloisons/septa, communication avec le canal de Wirsung et signes extra-pancréatiques.
- Variable cible de diagnostic (*diagnostic-resultat*) : classification nosologique en dix catégories pathologiques (cystadénome séreux, cystadénome mucineux, TIPMP, adénocarcinome, pseudokyste, etc.).

3.1.2 Justification du protocole de validation croisée

Dans le cadre d'un apprentissage automatique en santé, le choix de la méthode d'évaluation conditionne la fiabilité clinique du modèle prédictif :

- *Évaluation sur ensemble d'entraînement (Use Training Set)* : le modèle est testé sur les données mêmes qui ont servi à son apprentissage. Ce procédé engendre un biais d'optimisme majeur et masque le surapprentissage (*overfitting*), le classifieur apprenant le bruit des données sans capacité de généralisation sur de nouveaux patients.
- *Séparation par pourcentage (Percentage Split)* : les données sont divisées aléatoirement en deux sous-ensembles (par exemple 70 % pour l'entraînement et 30 % pour le test). Cette méthode présente l'inconvénient d'un biais d'échantillonnage

élevé, un découpage aléatoire unique pouvant concentrer arbitrairement des cas rares dans un seul sous-ensemble.

- *Validation croisée à 10 plis (10-fold Cross-Validation)* : le jeu de données est partitionné en dix sous-ensembles d'égale taille. À chaque itération, neuf plis sont combinés pour entraîner le modèle et le pli restant sert d'épreuve de test indépendante. Le processus est répété dix fois, de sorte que chaque observation fait exactement l'objet d'un test. Cette approche a été retenue car elle maximise l'exploitation des 73 instances disponibles tout en assurant une estimation plus robuste et réaliste des performances de généralisation.

3.1.3 Critères et métriques d'évaluation de la performance

L'évaluation clinique ne peut se satisfaire d'une simple mesure globale d'exactitude. Conformément aux principes d'évaluation des classifieurs médicaux, l'analyse repose sur la matrice de confusion croisant les prédictions et les étiquettes de référence (tableau 5) :

TABLE 5 – Structure générale de la matrice de confusion pour une classe cible

Réalité clinique	Prédiction positive	Prédiction négative
Malade (positif réel)	Vrai Positif (TP)	Faux Négatif (FN)
Sain (négatif réel)	Faux Positif (FP)	Vrai Négatif (TN)

À partir de cette matrice, les indicateurs cliniques fondamentaux sont définis :

- *La sensibilité ou taux de vrais positifs (Sensitivity / Recall / TPR)* :

$$TPR = \frac{TP}{TP + FN}$$

Elle mesure l'aptitude du test à détecter correctement les patients malades. En oncologie pancréatique, maximiser la sensibilité est impératif afin de minimiser les faux négatifs ($FNR = FN/(TP + FN)$), qui laisseraient une lésion maligne sans prise en charge.

- *La spécificité ou taux de vrais négatifs (Specificity / TNR)* :

$$TNR = \frac{TN}{TN + FP}$$

Elle quantifie l'aptitude à identifier correctement les lésions bénignes. Maximiser la spécificité permet de réduire le taux de faux positifs ($FPR = FP/(TN + FP)$), évitant ainsi à des patients non menacés de subir une chirurgie d'exérèse pancréatique lourde et risquée.

- *L'exactitude (Accuracy)* :

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Bien qu'intuitive, l'exactitude peut être trompeuse face à des distributions de classes fortement déséquilibrées.

- La *F-mesure* (*F-Score*) :

$$F - mesure = 2 \times \frac{Précision \times Rappel}{Précision + Rappel} \quad \text{où} \quad Précision = \frac{TP}{TP + FP}$$

Elle exprime la moyenne harmonique entre précision et rappel, offrant un compromis robuste.

- Le *coefficient de corrélation de Matthews (MCC)* : mesure d'accord équilibrée particulièrement rigoureuse, comprise entre -1 (désaccord total) et $+1$ (prédiction parfaite).
- La *courbe ROC et l'aire sous la courbe (AUC)* : tracé de la sensibilité (TPR) en fonction de $1 - spécificité$ (FPR) pour l'ensemble des seuils de décision possibles. Une valeur d'AUC égale à 0.5 traduit un classifieur purement aléatoire, tandis qu'une valeur tendant vers 1.0 reflète une excellente capacité de discrimination.

3.2 Expérimentation et comparaison des arbres de décision sous Weka Explorer

Les algorithmes d'arbres de décision présentent un intérêt majeur en médecine : ils construisent des représentations transparentes sous forme d'arborescences de règles logiques, directement compréhensibles par les praticiens, tout en tolérant naturellement les attributs hétérogènes et les valeurs manquantes.

Trois algorithmes représentatifs de la famille des arbres ont été testés sur le jeu de données sous validation croisée à 10 plis :

1. *J48* : implémentation sous Weka de l'algorithme C4.5 de Quinlan. Il partitionne l'espace des données en maximisant le ratio de gain d'information à chaque nœud, puis applique un élagage post-construction pour limiter le surapprentissage.
2. *LMT (Logistic Model Trees)* : algorithme hybride combinant un arbre de décision standard avec des modèles de régression logistique ajustés au niveau des nœuds terminaux (feuilles) via l'algorithme LogitBoost.
3. *RandomTree* : arbre de décision construisant chaque bifurcation à partir d'un sous-ensemble aléatoire d'attributs tirés sans remise, sans étape d'élagage.

Le tableau 6 regroupe les résultats expérimentaux obtenus pour chacun des trois modèles.

L'analyse comparative de ces indicateurs met en évidence une hiérarchie nette entre les algorithmes :

- L'algorithme LMT s'impose comme le plus performant avec un taux de bonne classification remarquable de 86.30 % et seulement 10 erreurs sur 73 cas. Sa statistique

TABLE 6 – Comparaison des performances des algorithmes d’arbres de décision sous Weka (73 instances)

Métrique d’évaluation	J48	LMT	RandomTree
Instances bien classées (Accuracy)	56 (76.71 %)	63 (86.30 %)	48 (65.75 %)
Instances mal classées	17 (23.29 %)	10 (13.70 %)	25 (34.25 %)
Statistique de Kappa	0.7330	0.8423	0.6084
Erreur absolue moyenne (MAE)	0.0599	0.0291	0.0725
Racine de l’erreur quadratique moyenne (RMSE)	0.2138	0.1518	0.2577
Erreur absolue relative (RAE)	34.07 %	16.51 %	41.19 %
Erreur quadratique relative (RRSE)	72.06 %	51.16 %	86.85 %

de Kappa atteint 0.8423, ce qui correspond selon les critères statistiques de Landis et Koch à un accord « presque parfait ». Ses erreurs résiduelles (MAE de 0.0291 et RMSE de 0.1518) sont deux fois plus faibles que celles des autres méthodes, témoignant d’une excellente calibration probabiliste due aux régressions logistiques terminales.

- L’algorithme J48 affiche un comportement satisfaisant avec 76.71 % d’exactitude et un Kappa substantiel de 0.7330. Il fournit une structure arborescente compacte et facilement auditable, mais peine davantage sur les frontières décisionnelles complexes où les classes se chevauchent.
- L’algorithme RandomTree présente les performances les plus faibles (65.75 % de réussite et un Kappa modéré de 0.6084). L’absence d’élagage et le tirage aléatoire des variables induisent une forte variance, particulièrement préjudiciable sur un échantillon de petite taille.

3.3 Analyse statistique sous Weka Experimenter : J48 versus Naive Bayes

Pour approfondir la comparaison entre les modèles et valider si un écart de performance observé est réellement significatif ou imputable aux fluctuations d’échantillonnage, des tests statistiques d’hypothèse ont été conduits dans le module *Experimenter* de Weka.

L’analyse a comparé l’arbre de décision J48 et le classifieur probabiliste Naive Bayes sur 10 exécutions de validation croisée à 10 plis, au moyen du test de Student apparié et corrigé (*Paired Corrected T-Tester*), avec un seuil de confiance de 95 % ($\alpha = 0.05$, test bilatéral). Le tableau 7 récapitule les résultats synthétiques obtenus.

TABLE 7 – Comparaison statistique bilatérale (Paired Corrected T-Tester, $\alpha = 0.05$) entre J48 et Naive Bayes

Critère d'évaluation	J48 (Base)	Naive Bayes	Significativité
F-mesure (F-Measure)	0.77	0.79	Pas de différence (0/1/0)
Taux de vrais négatifs (TNR / Spécificité)	0.94	0.95	Pas de différence (0/1/0)
Taux de vrais positifs (TPR / Sensibilité)	0.66	0.67	Pas de différence (0/1/0)
Taux de faux positifs (FPR)	0.06	0.05	Pas de différence (0/1/0)

L'interprétation clinique et statistique de ces résultats, évalués en prenant la classe **cas** (Cystadénome Séreux) comme classe positive d'intérêt face aux autres diagnostics différentiels, révèle plusieurs points notables :

- **Spécificité (TNR) et taux de faux positifs (FPR)** : les deux classifieurs présentent une spécificité élevée (0,94 pour J48 et 0,95 pour Naive Bayes) et un faible taux de faux positifs (6 % et 5 %). Cela indique qu'ils attribuent rarement à tort la classe CAS à une lésion appartenant à une autre catégorie.
- **Sensibilité (TPR / Rappel)** : le taux de vrais positifs se situe à 0,66 pour J48 et 0,67 pour Naive Bayes. Cette sensibilité modérée reflète la complexité à identifier exhaustivement tous les cystadénomes séreux au sein d'une cohorte restreinte de 73 patients, certains présentant des critères sémiologiques atypiques partagés avec d'autres kystes.
- **F-mesure et significativité statistique** : le compromis précision/rappel (F-mesure) est solide et comparable (0,77 pour J48 contre 0,79 pour Naive Bayes). Sur l'ensemble des métriques, le résultat du test statistique apparié est noté (0/1/0) : aucune différence statistiquement significative n'est mise en évidence entre J48 et Naive Bayes pour les métriques étudiées. Ce résultat ne permet toutefois pas de conclure à une équivalence stricte entre les deux modèles.

3.4 Conception de flux et étude des courbes ROC sous Weka Knowledge-Flow

L'environnement modulaire *KnowledgeFlow* de Weka a été exploité pour concevoir graphiquement les chaînes de traitement, analyser les compromis sensibilité/spécificité et tracer les courbes ROC (*Receiver Operating Characteristic*).

3.4.1 Visualisation du flux LMT et mise en évidence du surapprentissage

Dans un premier temps, une chaîne de traitement initiale a été assemblée dans l'environnement KnowledgeFlow afin d'évaluer le classifieur *Logistic Model Tree* (LMT) :

1. **ArffLoader** : chargement de la base de données `plc.arff` ;

2. **AttributeSummarizer** : composant de visualisation statistique permettant d'inspecter rapidement la distribution et les valeurs manquantes de chaque attribut médical ;
3. **ClassAssigner** : définition explicite de la variable cible **diagnostic-resultat** à prédire ;
4. **TrainTestSplitMaker** : module initial de partitionnement des données en sous-ensembles d'entraînement et d'évaluation ;
5. **LMT** : modèle recevant les flux d'apprentissage (*trainingSet*) et de test (*testSet*) ;
6. **ClassifierPerformanceEvaluator** : moteur de calcul des indicateurs de performance à partir des prédictions par lot (*batchClassifier*) ;
7. **TextViewer** et **ModelPerformanceChart** : modules finaux de restitution textuelle et de tracé graphique de la courbe ROC à partir des données de seuil (*threshold-Data*).

La première expérimentation, fondée sur un découpage unique entre apprentissage et test, conduit à une courbe ROC présentant une performance parfaite lorsqu'elle est calculée sur les données d'apprentissage (figure 8a). Ce profil constamment plaqué à la valeur maximale +1.0 constitue un indice de surapprentissage (*overfitting*) potentiel : le modèle semble ajuster très fidèlement les observations de la cohorte, sans que cette performance ne puisse être considérée comme représentative de sa capacité réelle de généralisation à de nouveaux patients. Afin de limiter la dépendance aux caractéristiques d'un découpage unique, le composant **TrainTestSplitMaker** a ensuite été remplacé par un **CrossValidationFoldMaker** configuré avec 10 plis. Ce protocole de validation croisée consiste à partitionner les données en dix sous-ensembles : le modèle est entraîné et évalué dix fois, chaque pli étant successivement utilisé comme ensemble de test tandis que les neuf autres servent à l'apprentissage. La figure 7 présente le flux final mis en œuvre dans KnowledgeFlow intégrant cette validation croisée à 10 plis, instancié ici avec l'arbre de décision J48 (dont l'agencement est strictement identique à celui utilisé pour LMT). Cette configuration permet d'obtenir une estimation robuste et non biaisée des taux de vrais positifs (TPR) et de faux positifs (FPR). Les courbes ROC obtenues avec cette nouvelle procédure sont présentées dans la figure 8b, mettant en évidence un profil de discrimination réaliste en évaluation hors échantillon.

3.4.2 Comparaison par courbes ROC et analyse de l'AUC : Naive Bayes versus Random Forest

Dans la suite des expérimentations, un flux parallèle a été conçu sous KnowledgeFlow afin de comparer deux algorithmes aux paradigmes distincts : le classifieur probabiliste *Naive Bayes* et l'algorithme d'ensemble *Random Forest*. La confrontation de leurs performances s'effectue au moyen de leurs courbes ROC et de l'évaluation de l'aire sous la courbe




FIGURE 7 – Conception du pipeline final d'apprentissage supervisé avec validation croisée (illustré ici avec l'arbre de décision J48) sous Weka KnowledgeFlow.




FIGURE 8 – Évolution du tracé ROC sous le module ModelPerformanceChart selon le protocole d'évaluation : à gauche, profil artificiellement parfait (courbe constante à +1.0) obtenu avec un découpage unique ; à droite, estimation réaliste obtenue après validation croisée à 10 plis avec CrossValidationFoldMaker.

(*Area Under the Curve*, AUC) au sein du module `ModelPerformanceChart`, présentées sur la figure 9.




FIGURE 9 – Comparaison des courbes ROC et de l’aire sous la courbe (AUC) entre Naive Bayes et Random Forest (classe cible `cas`) sous le module `ModelPerformanceChart`.

Ce flux intègre notamment le composant clé `ClassValuePicker`. Dans la mesure où la courbe ROC évalue une décision binaire (compromis sensibilité/spécificité), ce module permet d’opérer une décomposition *One-vs-Rest* en ciblant précisément la classe diagnostique d’intérêt (ici la classe `cas`, correspondant au cystadénome séreux) face à l’ensemble des autres lésions. Sur le plan médical, diagnostiquer formellement cette pathologie bénigne constitue un enjeu déterminant pour contribuer à l’orientation de la prise en charge et éviter au patient une chirurgie d’exérèse pancréatique inutile.

L’analyse de l’aire sous la courbe (AUC) à partir des tracés ROC de la figure 9 conduit aux conclusions suivantes :

- **Random Forest** génère une multitude d’arbres décisionnels décorrélés par tirage bootstrap (*bagging*) et sélection aléatoire de variables. Sa courbe ROC présente globalement de meilleures performances que celle de Naive Bayes, avec une AUC supérieure. Cela traduit une meilleure capacité à distinguer le cystadénome séreux des autres catégories kystiques.
- **Naive Bayes**, malgré l’hypothèse simplificatrice d’indépendance conditionnelle des 52 attributs, offre une courbe ROC très compétitive en escalier avec une AUC satisfaisante, confirmant sa robustesse pour un dépistage clinique de première intention.

4 Discussion et Synergie des Deux Approches

4.1 Comparaison entre approche symbolique et sous-symbolique

Les expérimentations menées successivement sous Protégé et sous Weka illustrent la complémentarité fondamentale existant entre les deux grands courants de l'intelligence artificielle en santé (tableau 8).

TABLE 8 – Synthèse comparative entre intelligence artificielle symbolique et sous-symbolique

Dimension d'analyse	Approche Symbolique (Protégé)	Approche Sous-symbolique (Weka)
Source de connaissance	Consensus médicaux formalisés par des experts.	Données empiriques de cohortes de patients.
Type de raisonnement	Déductif (règles logiques OWL et SWRL).	Inductif et statistique (apprentissage supervisé).
Explicabilité	Totale et auditable (traçabilité des inférences).	Variable (arbres explicables, forêts plus opaques).
Gestion des données	Dépend de la complétude explicite des assertions.	Robuste face au bruit et aux valeurs manquantes.
Rôle clinique	Formalisation du protocole de prise en charge.	Détection prédictive de motifs et classification.

4.2 Vers une architecture hybride d'aide à la décision (SADM)

Les résultats de ce travail confirment qu'aucun des deux paradigmes pris isolément ne peut résoudre l'intégralité du défi diagnostique des lésions pancréatiques :

- L'IA symbolique fournit un cadre sémantique rigoureux, explicable et conforme aux recommandations de bonne pratique, mais elle se trouve démunie lorsque des données observationnelles sont manquantes (comme l'absence d'assertion explicite du potentiel malin dans les requêtes SPARQL).
- L'IA sous-symbolique compense cette lacune en découvrant des régularités statistiques au sein des 52 attributs clinico-radiologiques et en fournissant des prédictions à haute exactitude (86.30 % avec LMT), mais elle ne propose pas de chaîne d'inférence thérapeutique personnalisée.

La solution d'avenir réside dans le couplage de ces deux technologies au sein d'une architecture hybride, telle que le système DIAT-PLC développé au sein de l'équipe de recherche :

1. Le modèle de fouille de données (LMT ou Random Forest) classe automatiquement le profil clinique du patient et prédit la probabilité d'appartenance à une classe lésionnelle à partir des données brutes.

2. Ce diagnostic statistique est ensuite injecté sous forme d’assertion factuelle dans l’ontologie OntoPLC.
3. Le moteur d’inférence logique (Drools) applique alors les règles SWRL pour confronter la prédiction statistique aux antécédents et à l’âge du patient, afin d’arrêter la décision thérapeutique finale (abstention, chirurgie ou surveillance) avec une justification médicale complète.

5 Conclusion et Perspectives

5.1 Bilan du travail réalisé

Ce projet a permis de concevoir et d'évaluer une chaîne complète d'aide à la décision médicale appliquée à une pathologie à fort enjeu pronostique : les lésions kystiques du pancréas.

Dans un premier volet dédié à l'intelligence artificielle symbolique, l'ontologie Onto-PLC a été structurée sous Protégé autour de huit concepts fondamentaux, modélisant les liens entre patients, lésions, examens radiologiques et options thérapeutiques. L'interrogation de la base de cas par des requêtes SPARQL et l'automatisation de déductions cliniques par des règles SWRL ont démontré la capacité du système à intégrer les recommandations d'experts de manière transparente et explicable.

Dans un second volet consacré à l'intelligence artificielle sous-symbolique, l'exploitation de la base de données cliniques sous Weka a permis de construire et de comparer plusieurs familles d'algorithmes de classification. L'algorithme LMT s'est distingué par une exactitude de 86.30 % et un coefficient Kappa de 0.8423, surpassant les arbres de décision J48 et RandomTree. Les analyses statistiques sous Weka Experimenter et l'étude des courbes ROC sous KnowledgeFlow ont validé la robustesse du protocole en validation croisée et mis en garde contre les biais de surapprentissage.

5.2 Limites et perspectives d'évolution

Plusieurs axes d'amélioration peuvent être envisagés pour prolonger ce travail :

- *Élargissement de la cohorte clinique* : les expérimentations ont été menées sur une base de 73 patients. Bien que statistiquement significatifs, ces résultats gagneraient à être validés sur des registres multicentriques de plus grande envergure.
- *Intégration d'imagerie directe* : les variables radiologiques ont été intégrées sous forme de descripteurs tabulaires experts. L'intégration de réseaux de neurones convolutifs (CNN) pour extraire directement les biomarqueurs morphologiques à partir des fichiers sources DICOM (TDM et IRM) constituerait une avancée majeure.
- *Déploiement d'une interface praticien unifiée* : le développement d'un logiciel intégré couplant l'API Weka et l'API OWL/RDFLib permettrait aux cliniciens de saisir les paramètres d'un patient et de recevoir instantanément à la fois la probabilité nosologique et la recommandation thérapeutique argumentée.